GSLC Sesi 5

Nama: Farrell Axel Suwandi
NIM: 2802451062

A. Analisis Konseptual (Bobot: 20%)

1. Efek Regularisasi pada Batch Normalization

Batch Normalization (BN) menghitung mean dan varians aktivasi pada setiap mini-batch saat pelatihan. Fluktuasi statistik antar mini-batch memasukkan stochastic noise ke dalam representasi tiap sampel, sehingga aktivasi satu gambar terikat pada variasi sampel pendampingnya. Gangguan stokastik ini mencegah unit tersembunyi beradaptasi berlebihan pada nilai aktivasi tertentu, menghasilkan efek mild regularization yang kerap menekan kebutuhan Dropout konvensional [1]. Namun, asumsi penggantian Dropout tidak berlaku pada batch size kecil (misal B <= 8), domain dengan variasi intra-batch ekstrem, atau ketika data latih tidak i.i.d., karena estimasi statistik menjadi sangat bising dan memicu instabilitas konvergensi. Selain itu, pergeseran mode train (statistik batch) ke eval (running statistics) pada transfer learning data terbatas dapat menurunkan akurasi jika running statistics terdistorsi pembaruan agresif.

2. Degradasi Jaringan Dalam dan Formulasi Residual

Pada plain CNN tanpa skip connection, penambahan kedalaman lapisan memicu degradation problem di mana training accuracy justru merosot, bukan akibat overfitting karena training loss turut membengkak. Secara teoritis, jaringan lebih dalam minimal dapat menyamai jaringan dangkal bila lapisan tambahan mempelajari identity mapping, namun optimasi nonlinier berbasis SGD/Adam gagal menemukan pemetaan identitas tersebut melalui tumpukan convolution dan ReLU [3]. Arsitektur ResNet mengatasi kendala ini dengan merumuskan kembali pemetaan target menjadi residual F(x) = H(x) - x, sehingga output blok bernilai y = F(x) + x. Saat backpropagation, aturan rantai gradien menghasilkan dLoss/dx = (dLoss/dy) * (dF/dx + I). Matriks identitas I menyediakan jalur langsung tanpa attenuasi perkalian bobot berulang, memitigasi vanishing gradient dan menjamin aliran gradien tetap lancar hingga lapisan awal.

3. Feature Extraction vs. Fine-Tuning

Feature extraction membekukan seluruh representasi backbone (requires_grad = False) dan hanya melatih linear head baru, sedangkan fine-tuning membuka sebagian atau seluruh blok representasi pretrained. Perbandingan ditinjau dari empat dimensi: (1) Trainable parameters: feature extraction sangat hemat (hanya 5.130 parameter pada ResNet-18 10 kelas), sementara fine-tuning layer4 mencapai 8,40 juta parameter. (2) Volume data: feature extraction unggul pada small-data regime (ratusan sampel) karena risiko overfit minimal; fine-tuning membutuhkan data lebih besar atau regularisasi ketat. (3) Beban komputasi/memori: feature extraction tidak menghitung gradien backbone

sehingga memory footprint aktivasi dan komputasi backward pass jauh lebih ringan. (4) Risiko destructive gradient updates: feature extraction nol risiko merusak fitur bawaan ImageNet; fine-tuning rentan merusak representasi jika learning rate awal terlalu besar. Kriteria praktis: gunakan feature extraction bila dataset target kecil dan mirip domain ImageNet; terapkan fine-tuning bertahap bila kapasitas komputasi memadai dan fitur domain memerlukan adaptasi representasi tingkat tinggi [4].

4. Kaidah Penerapan Data Augmentation

Secara metodologis, data augmentation hanya diaktifkan pada train set guna memperluas distribusi empiris sampel dan menekan generalization gap tanpa mengubah ground truth. Pada validation dan test set, pipeline augmentation wajib dinonaktifkan dan diganti transformasi deterministik (Resize, CenterCrop, Normalization). Evaluasi memerlukan tolok ukur performa yang konsisten dan merefleksikan distribusi asli domain target; menerapkan augmentasi stokastik saat evaluasi akan memasukkan noise acak pada metrik performa serta berisiko data leakage jika augmentasi dilakukan sebelum pemisahan data. Contoh transformasi yang tidak layak untuk klasifikasi ras hewan peliharaan adalah RandomErasing atau Crop agresif berlebih (skala < 0.2) yang menghilangkan area kepala/wajah atau memotong seluruh pola corak bulu. Transformasi tersebut merusak semantik pembeda morfologi ras (seperti pola totol Bengal vs tumpukan warna Abyssinian) sehingga label ground truth kehilangan dasar visual yang sah.

5. Mitigasi Catastrophic Forgetting

Catastrophic forgetting terjadi saat gradien berskala besar dari classifier head acak merambat balik ke lapisan backbone pretrained, menimpa bobot representasi visual umum (fitur tepi, tekstur, bentuk) yang dipelajari dari ImageNet secara destruktif demi meminimalkan error jangka pendek pada dataset baru yang kecil. Strategi mitigasi konkret pertama adalah differential learning rate (discriminative fine-tuning), yaitu menetapkan learning rate kecil pada backbone (misal 1e-4 pada layer4) dan learning rate lebih tinggi pada linear head (1e-3). Secara teoritis, metode ini menjaga representasi fitur fundamental tetap stabil sembari memungkinkan head berkonvergensi cepat. Strategi kedua adalah gradual unfreezing, yaitu melatih linear head terlebih dahulu hingga stabil selama beberapa epoch awal, kemudian membuka blok konvolusi teratas secara bertahap. Hal ini menjamin bahwa saat bobot backbone diperbarui, gradien yang diterima berasal dari classifier yang telah berorientasi benar, bukan dari inisialisasi acak yang destruktif [4].

B. Eksperimen Praktik (Bobot: 40%)

1. Pemilihan Dataset

Mengikuti rekomendasi utama penugasan, dataset yang digunakan adalah Oxford-IIIT Pet [5]. Dipilih 10 kelas seimbang, yaitu 5 ras kucing (Abyssinian, Bengal, Birman, Bombay, British Shorthair) dan 5 ras anjing (American Bulldog, American Pit Bull Terrier, Basset Hound, Beagle, Boxer). Penggabungan split resmi trainval dan test menghasilkan 1.981 gambar terverifikasi tanpa anomali. Pembagian data internal dilakukan secara stratified dengan random seed 42: 70% data latih (1.386 gambar), 15% data validasi (297 gambar),

dan 15% data uji (298 gambar). Seluruh kondisi B1 s.d. B5 dievaluasi pada split tetap ini guna menjamin validitas komparasi.

2. Standarisasi Protokol Eksperimen

Protokol eksperimen distandarisasi secara ketat: arsitektur utama ResNet-18 dengan bobot pretrained IMAGENET1K_V1 (kecuali B1 scratch). Dimensi input 224 x 224 piksel dengan normalisasi standar ImageNet (mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225]). Hyperparameter pelatihan: batch size 32, optimizer AdamW (weight decay 0.01), loss function CrossEntropyLoss. Early stopping memonitor validation loss dengan patience 4 epoch (maksimum 18 epoch). Random seed ditetapkan 42 untuk PyTorch, NumPy, dan Python built-in demi reproduksibilitas deterministik. Setiap kondisi mencatat parameter trainable, learning rate per kelompok, epoch konvergen, waktu pelatihan, akurasi validasi, dan Macro F1 test.

3. Matriks Kondisi Eksperimen

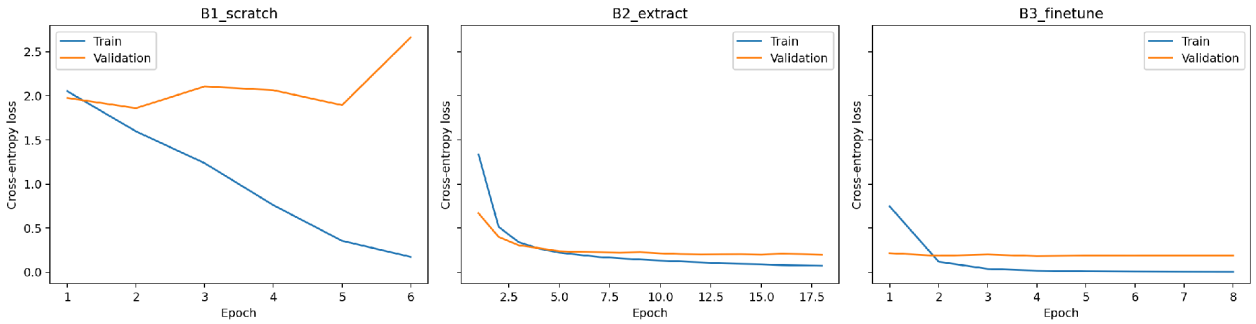
Lima kondisi eksperimen dijalankan secara terkontrol: (B1) Baseline from Scratch: ResNet-18 inisialisasi acak (weights=None), lr=1e-4; (B2) Feature Extraction: ResNet-18 pretrained, seluruh backbone dibekukan (requires_grad=False, BatchNorm eval), hanya layer fc dilatih (lr=1e-3); (B3) Progressive Fine-Tuning: ResNet-18 pretrained, unfreeze layer4 (lr=1e-4) dan fc (lr=1e-3); (B4) Uji Kontrol Data Augmentation: konfigurasi B3 ditambah augmentasi data aktif pada data latih (RandomResizedCrop, HorizontalFlip, RandomRotation 15 derajat, ColorJitter); (B5) Arsitektur Pembanding: konfigurasi fine-tuning terbaik diuji pada arsitektur efisien MobileNetV3-Small (unfreeze blok fitur terakhir lr=1e-4, classifier lr=1e-3).

C. Laporan dan Analisis (Bobot: 35%)

1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Kode	Strategi Pelatihan	Trainable Params	Learning Rate	Epoch Konvergen	Waktu (s)	Val Acc (%)	Test Macro F1
B1	Baseline from Scratch	11.181.642	1e-4	2 / 6	67,4	38,38	0,3376
B2	Feature Extraction	5.130	1e-3	18 / 18	122,7	95,62	0,9433
B3	Progressive Fine-Tuning	8.398.858	layer4: 1e-4, fc: 1e-3	4 / 8	64,2	95,29	0,9432
B4	Uji Kontrol Augmentasi	8.398.858	layer4: 1e-4, fc: 1e-3	2 / 6	63,6	93,60	0,9119
B5	Arsitektur MobileNetV3	657.546	last: 1e-4, head: 1e-3	9 / 13	81,3	90,91	0,9268

Catatan metrik: sumber log mentah artifacts/summary.csv dan metrics.csv. Kolom Epoch Konvergen menyatakan best_epoch / total_epoch. B2 mencapai batas maksimal 18 epoch pelatihan.



Gambar 1. Kurva komparasi training loss vs validation loss pada kondisi B1 (Scratch), B2 (Feature Extraction), dan B3 (Fine-Tuning).

2. Pembahasan Analisis Komparatif

1. Disparitas Tajam Baseline Scratch (B1) vs Pretrained (B2 & B3): Pelatihan dari inisialisasi acak (B1) hanya meraih akurasi validasi 38,38% dan test Macro F1 0,3376, tertinggal lebih dari 60 poin persentase di belakang paradigma transfer learning (B2 0,9433 dan B3 0,9432). Kurva loss Gambar 1 memperlihatkan B1 mengalami overfitting parah sejak epoch ke-2 (training loss turun ke 0,1736 namun validation loss melonjak ke 2,6646). Fenomena ini mengonfirmasi konsep Slide 14-16: melatih 11,18 juta parameter konvolusi dari nol pada data terbatas (1.386 gambar) tidak menyediakan sinyal supervisi yang cukup untuk membangun representasi visual hirarkis (tepi, tekstur, kontur). Sebaliknya, transfer learning memanfaatkan filter visual kaya hasil pra-latih ImageNet-1K sehingga optimasi hanya perlu memetakan fitur ke 10 kelas target.

2. Trade-Off Performa vs Stabilitas: Feature Extraction (B2) vs Progressive Fine-Tuning (B3): B2 dan B3 menghasilkan test Macro F1 yang setara (0,9433 vs 0,9432), namun memiliki karakteristik dinamika pelatihan berbeda. B3 mencapai validation loss terendah yang lebih optimal (0,1813 pada epoch 4) dibandingkan B2 (0,1984 pada epoch 18). Dari segi stabilitas, B2 jauh lebih kebal overfitting karena hanya memperbarui 5.130 parameter classifier head, tetapi membutuhkan 18 epoch penuh untuk konvergen. Sebaliknya, B3 dengan 8,40 juta parameter trainable mencapai konvergensi optimal lebih cepat (epoch 4, durasi 64,2 detik vs 122,7 detik pada B2). Hal ini menunjukkan unfreezing selektif pada layer4 dengan differential learning rate (1e-4) berhasil mempercepat adaptasi representasi tanpa memicu destructive gradient updates.

3. Peran Uji Kontrol Data Augmentation (B4) terhadap Generalization Gap: Perbandingan langsung kondisi identik B3 (tanpa augmentasi) vs B4 (dengan augmentasi aktif) memperlihatkan peran regularisasi augmentasi yang nyata namun memiliki trade-off spesifik. Pada B3, training accuracy mencapai 100% dengan gap terhadap akurasi validasi sebesar 4,71% (indikasi fitting kuat). Pada B4, selisih akurasi data latih (93,29%) terhadap data validasi (93,60%) teredam sepenuhnya menjadi -0,31%, membuktikan augmentasi efektif menekan memorisasi sampel latih. Namun, Macro F1 uji B4 tercatat 0,9119 (sedikit di bawah B3 0,9432). Hal ini mengindikasikan intensitas augmentasi gabungan (Crop 0.8, Rotation 15 derajat, ColorJitter) pada rezim data terbatas dapat menambah

kompleksitas optimasi yang menuntut jadwal epoch lebih panjang untuk mencapai titik optimum global.

3. Failure Analysis (Analisis Kasus Misklasifikasi)

Model terbaik yang dipilih berdasarkan validation loss terendah adalah ResNet-18 Progressive Fine-Tuning (B3, val loss 0,1813). Dari 298 sampel uji, model menghasilkan total 17 misklasifikasi (akurasi uji 94,30%). Gambar 2 menampilkan 8 sampel kegagalan dengan confidence score tertinggi beserta hipotesis teknis penyebab kesalahan:



Gambar 2. Delapan sampel citra uji dengan misklasifikasi keyakinan tertinggi pada model terbaik ResNet-18 Fine-Tuning (B3).

1. Abyssinian -> Bengal (Confidence: 93,1%): Ambiguitas visual pola corak dan oklusi: tubuh kucing tertutup selimut hijau tebal serta watermark diagonal Shutterstock menutupi area wajah, menyamarkan tekstur ticking khas Abyssinian menjadi mirip rosette Bengal.

2. Boxer -> American Bulldog (Confidence: 92,7%): Kedekatan morfologi kraniofasial ekstrem: ras Boxer putih dengan moncong lebar dan corak kuping cokelat sangat menyerupai struktur kepala American Bulldog pada jarak close-up tanpa visibilitas postur tubuh.

3. Beagle -> American Pit Bull Terrier (Confidence: 89,4%): Modalitas domain bergeser drastis (citra grayscale monokrom): anjing mengenakan syal dan pakaian bergaris yang menutupi corak tri-color khas Beagle; sudut samping kepala membuat model salah mengidentifikasi ras.

4. British Shorthair -> Bombay (Confidence: 81,0%): Pencahayaan buruk dan resolusi rendah: kucing abu-abu berada di bawah bayangan meja kayu yang pekat dan cahaya

matahari parsial, menyebabkan warna bulu British Shorthair tampak hitam legam menyerupai Bombay.

5. American Pit Bull Terrier -> American Bulldog (Confidence: 80,1%): Ambiguitas taksonomi visual tinggi: anjing pit bull berbulu dominan putih dengan postur muka lebar memiliki overlap visual yang sangat tinggi dengan American Bulldog tipe Johnson/Scott.

6. American Bulldog -> Boxer (Confidence: 79,7%): Jarak pengambilan ekstrem (long-shot outdoor): anjing berdiri jauh di atas dermaga kayu tepi danau; fitur wajah tidak teresolusi dengan tajam dan siluet moncong tertutup bayangan kontras latar belakang.

7. Basset Hound -> Beagle (Confidence: 78,5%): Sudut pengambilan ekstrem (high top-down angle): anjing difoto tegak lurus dari atas saat tengkurap di rumput, menyamarkan ciri khas kaki pendek melengkung Basset Hound sehingga corak kepala menyerupai Beagle.

8. American Pit Bull Terrier -> American Bulldog (Confidence: 78,3%): Oklusi interior kabin mobil: postur tubuh tertutup dashboard dan jok mobil; pencahayaan atas dari sunroof membiaskan proporsi kepala anjing cokelat-putih ke arah morfologi Bulldog.

4. Rekomendasi Rekayasa dan Batasan Eksperimen

Rekomendasi Rekayasa untuk Lingkungan Produksi:1. Strategi Pelatihan Optimal pada Rezim Data Terbatas: Untuk deployment industri dengan data berlabel terbatas (~1.000 s.d. 2.000 citra) pada domain visual natural, Progressive Fine-Tuning (B3) adalah strategi terbaik jika performa loss dan konvergensi cepat menjadi prioritas. Namun, jika anggaran komputasi sangat terbatas atau sistem harus dijalankan pada perangkat edge tanpa GPU training, Feature Extraction murni (B2) merupakan pilihan rekayasa yang sangat solid: hanya melatih 5.130 parameter dan menghasilkan Macro F1 uji yang setara (0,9433 vs 0,9432) dengan stabilitas tinggi bebas risiko catastrophic forgetting.2. Operational Constraints: Fine-tuning wajib menerapkan differential learning rate (rasio lr_backbone : lr_head = 1:10) dan pembekuan layer konvolusi awal (layer1 s.d. layer3) guna mencegah kerusakan representasi visual dasar. Augmentasi data perlu dikalibrasi secara konservatif agar tidak mengaburkan batas pembeda antar kelas.3. Evaluasi Arsitektur Ringan (B5 MobileNetV3-Small): Menawarkan penghematan memori model drastis (total parameter 1,53 juta vs 11,18 juta pada ResNet-18) dengan Macro F1 yang tetap kompetitif (0,9268). Sangat direkomendasikan untuk operational constraint dengan batasan memori dan latensi inference perangkat bergerak.Batasan Eksperimen (Limitations):Studi ini memiliki sejumlah limitasi empiris: (a) Pengujian berbasis single random seed (seed 42); variansi stokastik bobot inisialisasi belum diukur melalui k-fold cross-validation. (b) Subset dibatasi pada 10 kelas ras hewan peliharaan, sehingga temuan belum tentu tergeneralisasi pada tugas klasifikasi berbutir halus (fine-grained) berskala ratusan kelas atau domain non-natural (medis/satelit). (c) Batas maksimum 18 epoch menyebabkan kondisi B2 belum berhenti via early stopping patience.

5. Eksplorasi Tambahan: Analisis Pergeseran Representasi Visual (Nilai Tambah)

Sesuai best practice adaptasi domain (Slide 29), representasi aktivasi blok layer4 mengalami pergeseran terarah sebelum dan sesudah fine-tuning. Sebelum fine-tuning (B2 feature extraction), representasi backbone bersifat generik ImageNet yang terdistribusi luas pada tekstur latar belakang dan kontur umum tubuh hewan. Setelah proses fine-tuning selektif pada layer4 (B3), gradien domain spesifik menggeser receptive field efektif filter tingkat tinggi untuk lebih memusatkan atensi aktivasi pada area diskriminatif kunci ras hewan, seperti geometri moncong, bentuk telinga, dan pola mikro corak bulu wajah, sembari menekan aktivasi noise latar belakang (rumput, lantai, perabot). Pergeseran representasi terarah ini menjelaskan mengapa B3 berhasil menurunkan validation loss hingga 0,1813 dibandingkan 0,1984 pada B2.

6. Integritas Akademik dan Kebijakan Penggunaan AI (Bobot: 5%)

AI: ChatGPT

Cara Penggunaan: Bantuan dalam arahan pembuatan kode, debugging kode, pemahaman kode, arah pembuatan laporan, pencarian referensi.

Referensi Ilmiah:

[1] S. Ioffe and C. Szegedy, "Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift," in ICML, 2015.

[2] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A Simple Way to Prevent Neural Networks from Overfitting," JMLR, 2014.

[3] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in CVPR, 2016.

[4] Bahan Tayang Perkuliahan Sesi 05: "Advanced CNNs and Transfer Learning" (Slide 5 s.d. 30), 2026.

[5] O. M. Parkhi, A. Vedaldi, A. Zisserman, and C. V. Jawahar, "Cats and Dogs," in CVPR, 2012.